Géodata Paris

Université Gustave Eiffel

Rapport de projet

Cycle des ingénieurs de l'ENSG 3ème année IGAST

# Analyse du report modal suite à la réouverture d'une ligne ferroviaire



**Éléonore Lagourgue, Quentin Rameau-Quinchon, Niels Saura**

Mars 2026

# Table des matières

**Introduction** **4**

**1 Présentation du cadre de modélisation du trafic dit *Four Step Model*** **5**
1.1 Structure de l'article . . . 5
1.2 Historique du Modèle . . . 5
1.3 Présentation du cadre du Transportation System Analysis . . . 6
1.4 Définition des zones d'étude et données . . . 6
1.5 Etape 1 : Trip Generation . . . 7
1.6 Etape 2 : Trip Distribution . . . 7
1.7 Etape 3 : Mode Choice . . . 8
1.8 Etape 4 : Route Choice . . . 8
1.9 Rétroaction du modèle . . . 8
1.10 Limites du modèle pour notre sujet . . . 8

**2 Matériel et méthodes** **10**
2.1 Sources de données . . . 10
2.1.1 Les données de mobilité . . . 10
2.1.2 Les données vecteur . . . 10
2.2 Zone d'étude . . . 10
2.2.1 Définition de la zone d'étude . . . 11
2.2.2 Calcul des pourcentages de trajets internes à notre zone d'étude 11

**3 Traitement des données** **16**
3.1 Création des graphes . . . 16
3.1.1 OSMnX . . . 16
3.1.2 Le graphe ferroviaire . . . 16
3.2 Matrice OD . . . 17
3.3 Fusion des Graphes . . . 18

**4 Modélisation du report Modal** **20**
4.1 Modélisation du Trafic Actuel Dans notre zone d'étude . . . 20
4.1.1 Modélisation du Trafic Routier . . . 20
4.1.2 Modélisation du Trafic Ferroviaire . . . 23
4.2 Modélisation du Report Modal par Implémentation d'Hypothèses . . . 24
4.3 Modélisation du Report Modal par Choix Discret . . . 25
4.3.1 Modèle de choix discret et maximisation de la log vraisemblance appliqués à notre sujet . . . 25
4.3.2 Calcul de la matrice des paramètres . . . 27

4.4 Détermination des Coefficients de préférence . . . . . 30
4.4.1 Ajout d'un paramètre confort . . . . . 31
4.4.2 Prédictions des parts modales . . . . . 31
4.4.3 Hypothèses sur l'échec de la méthode et perspectives d'améliorations . . . . . 32

**Conclusion** **34**

# Introduction

La Fédération Nationale des Associations d'Usagers des Transports est une organisation de consommateurs à but non lucratif, regroupant 160 associations d'usagers des transports au niveau national et local. Elle compte près de 80000 adhérents aux profils différents tels que des usagers de transports en commun, piétons, cyclistes ou même des riverains subissant les nuisances liées au développement des infrastructures de transport, et existe depuis 40 ans. La FNAUT se définit comme un groupe de pression d'intérêt général, dans le but de démocratiser et favoriser les aménagements et déplacements en transports en commun. Elle est aujourd'hui présente dans de grandes instances telles que le Conseil National de la Consommation, le Conseil National des Transports, ou le Conseil d'Administration de la RATP.
Le 13 décembre 2025, la FNAUT publie un Plan National de Réouvertures de Lignes ferroviaires. Dans ce plan, la Fédération demande la réouverture de 49 lignes ferroviaires réparties sur l'ensemble de la métropole. L'estimation du coût de ce plan est d'environ 300 millions d'euros sur 15 ans, qualifié d'extrêmement faible par l'organisation. L'objectif de ce plan est d'attirer l'attention sur des lignes qui seraient en capacité d'accueillir 1000 à 4000 voyageurs par jour, tout en faisant du lobbying pour faire pencher des décisions politiques en s'appuyant sur des arguments écologiques, économiques et de sécurité.
Cette publication est la première de la sorte, mais la Fédération compte bien renouveler ces plans dans le cas où aucune de leur revendication n'est écoutée.
Ce rapport a été publié dans un contexte de perte en longueur de voie en France et ce, malgré l'ouverture de nouvelles lignes, notamment des lignes TGV. Pourtant, les Français préfèrent de plus en plus le train par rapport à la voiture.
En 2024, l'Autorité de Régulation des Transports (ART) observe une augmentation de 6% de voyageurs dans les trains par rapport à 2023, soit une augmentation de même ampleur que l'année précédente. Et cette hausse est portée par les "services conventionnés interurbains" (TER et Intercités) avec une progression de $+11\%$ par rapport à 2023 (Beaughon et al., Juin 2025). Dans son rapport, l' ART met en lumière la nécessité d'avoir un réseau ferré de qualité et bien entretenu notamment dans la perspective d'une transition écologique des transports en contexte de changement climatique (d'Harcourt et al., Juillet 2023). Aujourd'hui, l'enjeu est donc d'inciter les personnes à utiliser le train. Et les lignes pour les trajets du quotidien sont des cibles de choix pour cet objectif. Pourtant, ce sont les lignes qui ont été les plus touchées par les fermetures en France. Nous chercherons donc à analyser les réouvertures possibles proposées par la FNAUT, en particulier la ligne Troyes-Saint-Florentin et l'impact sur le report modal.

# Chapitre 1 Présentation du cadre de modélisation du trafic dit *Four Step Model*

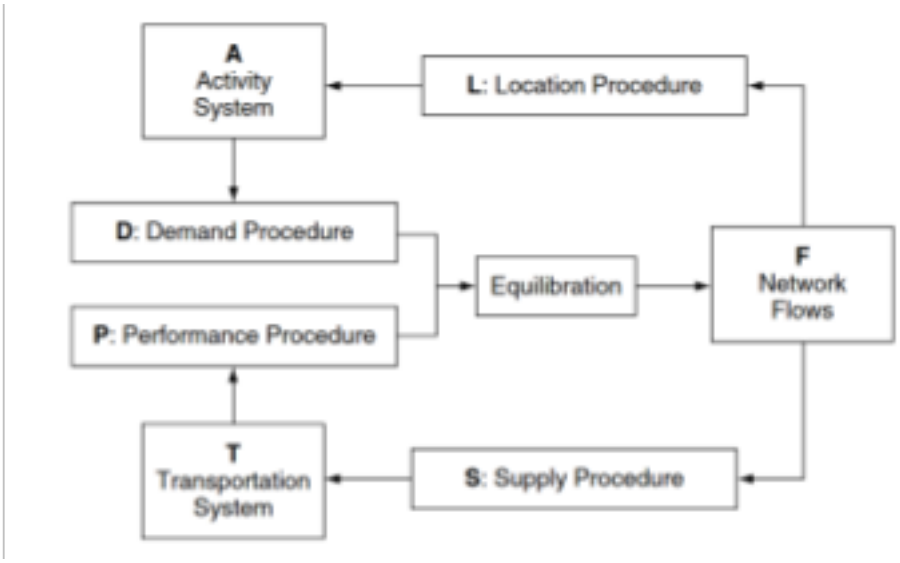
Pour estimer les méthodes standards de modélisation de la demande de transport, nous nous sommes intéressés au chapitre intitulé "The Four-Step Model", écrit par Michael G. Mc Nally et extrait du livre the Handbook of Transport Modelling (2007) dirigé par David A. Hensher et Kenneth J. Button. Notre choix est dû au fait que la modélisation en quatre étapes est le cadre le plus standard de la modélisation du trafic, qui supporte un nombre important de sous-modèles pour chacunes des différentes étapes. Cela nous a ainsi semblé un bon point de départ pour proposer in fine une méthode d'estimation du report modal à l'occasion de la réouverture de voies ferrées sur un cas d'étude particulier.

## 1.1 Structure de l'article

Le chapitre est structuré de la manière suivante : Introduction de la méthode du Four Step Model (FSM) et de son histoire Présentation du cadre général du Transportation System Analysis Considérations sur les échelles d'étude et leur définition et les données nécessaires au modèle Les quatre dernières parties présentent en détail chaque étape du modèle et une application à un "Sample Problem"

## 1.2 Historique du Modèle

L'historique du modèle présenté est intéressant parce qu'il permet de comprendre pourquoi celui-ci s'est imposé comme standard. L'auteur précise fréquemment que ce modèle n'est pas forcément le meilleur, cependant sa large adoption est liée à la relative facilité à le mettre en place ainsi qu'à son histoire. Le modèle est apparu aux Etats-Unis en 1950, dans une période d'essor économique d'après-guerre et de fort développement de l'infrastructure de transport. Ce champ disciplinaire est ensuite devenu une pierre angulaire des politiques de développement urbain et a été encouragé à différentes reprises notamment pour permettre la mise en œuvre de législations sur la cohérence du développement urbain et la prise en compte de l'environnement. Le FSM n'est donc pas seulement un champ de recherche scientifique mais également une condition de la planification urbaine.




## 1.3 Présentation du cadre du Transportation System Analysis

L'auteur rattache le FSM au cadre plus général du Transportation System Analysis définit principalement par Florian et Manheim. Ce cadre est résumé dans la figure reproduite ci-dessous, issue du chapitre.
Dans cette figure, D représente la demande générale en transport à un niveau zonal. P représente le nombre de trajets par mode effectif sur un lien, qui est un arc du graphe de transport. A est l'activité, ensemble de données socio-démographiques qui détermine la demande. L représente l'évolution de la localisation pour tenir compte du traffic et de l'accessibilité et S est l'évolution de l'offre de transport. Ces deux derniers éléments sont totalement absents du FSM, ce qui est une limite soulevée par l'auteur. Ce cadre général permet de définir les interactions entres les différentes composantes socio-économiques qui influent sur le trafic : l'activité détermine la demande ; celle-ci en fonction de la saturation du réseau permet de définir l'utilisation effective du réseau de transport, qui influe à son tour sur la localisation des individus et l'offre de transport, redéfinissant enfin la demande et la saturation du réseau et permettant de réitérer l'analyse.

## 1.4 Définition des zones d'étude et données

Le FSM nécessite de définir une zone d'étude délimitée. A l'intérieur de ces zones d'étude, il est nécessaire de définir des "traffic analysis zones" (TAS), qui sont l'échelle pertinente pour établir ultérieurement les matrices origine/destination et pour agréger les enquêtes sur les ménages. L'auteur s'étend peu sur la manière de gérer le traffic lié à des trajets passant en dehors de la zone d'étude mais il explique qu'ils sont gérés par un modèle plus simple appelé "growth factor". L'interface entre le graphe de transport et les TAS est géré par des connections entre le réseau et les centroïdes des TAS. En France et pour notre cas d'étude, une échelle de TAS qui semble toute indiquée, serait celle des IRIS de l'INSEE. L'auteur prévient du fait que ce modèle nécessite des données issues d'enquête assez importantes. En particulier le type de données nécessaire est

généralement regroupé sous le terme de "household travel survey" / enquête sur les déplacements des ménages. Ces données doivent essentiellement inclure des informations socio-économiques sur les ménages, en particulier le niveau de revenu, le nombre d'individus, le nombre de personnes actives et le nombre de voitures. Cela est utilisé pour générer l'attraction et la production à la première étape. Elles doivent également inclure "activity-travel data", c'est-à dire une détaillée sur le mode de transport, la durée et la distance de chaque déplacement pendant une certaine période. Cela est utilisé pour calibrer le choix de mode à la troisième étape.

## 1.5 Etape 1 : Trip Generation

La première étape consiste à générer l'attraction et la production pour chaque TAS. Attraction et Production sont les termes utilisés dans ce cadre conceptuel pour décrire le nombre de trajets attirés / à destination d'une zone et le nombre de trajets produits / partants d'une zone. Le FSM considère l'attraction et la production comme de purs produits de l'activité, extrapolée à partir des enquêtes socio-économiques. En d'autres termes, il s'agit de variables exogènes au modèle. L'auteur déplore ainsi la non prise en compte de l'accessibilité d'une zone et la non intégration de cette étape dans la réitération du modèle. La méthode la plus utilisée à cette étape est la modélisation par catégorie. Pour la détermination de l'attractivité, on établit des sous catégories de ménages en fonction par exemple du revenu et du nombre de voiture. On établit le nombre moyen de trajets par personne et par type de ménage à partir des données d'entrée et on extrapole le nombre de trajets pour chaque mode et chaque TAS. L'auteur pointe le fait que cette méthode est plus difficile à appliquer pour la production, car les données sont généralement plus centrées sur les ménages. En particulier pour certaines zones, comme les universités, il faut faire appel à des modélisations à part. Enfin, les attractions et productions sont égalisées par mode de transport en prennant comme référence les productions, plus fiables. On produit également une table des A et P pour chaque type de trajet. Dans le chapitre, l'auteur distingue ainsi les trajets domicile-travail, domicile-autre, autre.

## 1.6 Etape 2 : Trip Distribution

L'étape 2 du modèle consiste à transformer les informations d'attraction et production pour chaque TAS en matrice Origine Destination. Pour cela, le modèle dominant est le modèle gravitaire dont l'équation est reproduite ci-dessous.

$$T_{ij} = a_i b_j P_i A_j f(t_{ij})$$

On a ici Tij le nombre de trajets du TAS i au TAS j, Pi la production de i, Aj l'attraction de j. tij l'impédance entre i et j (coût financier, distance, temps, agrégation de ces paramètres). f est la fonction d'impédance, qui donne la loi de décroissance du nombre de trajets avec l'augmentation de l'impédance. ai et bj sont des paramètres qui interviennent dans la calibration de f sur les données réelles pour garantir que l'attraction et la production soient égaux. La calibration se fait typiquement en définissant un profil de trajets selon le temps, la distance et le coût à partir des données réelles et en ajustant f pour que la distribution des trajets modélisées ait les mêmes proportions que

celles observées. A cette étape on peut introduire une information temporelle, en faisant typiquement une table pour le matin et une table pour l'après-midi. L'auteur discute également la pertinence d'utiliser des facteurs spécifiques à chaque cellule, nommés Kij, pour coller plus aux données, au détriment de la capacité de généralisation.

## 1.7 Etape 3 : Mode Choice

Cette étape vise à extrapoler le nombre de trajets pour chaque mode à partir des matrices origines destinations. La modélisation utilisée est appelée modélisation discrète : c'est une modélisation fondée sur la maximisation de l'utilité individuelle. L'auteur ne détaille pas cette étape par manque de place mais on peut rappeler que cette étape recourt généralement à la modélisation logit. Celle-ci consiste à modéliser la probabilité d'utiliser un mode pour un individu comme exp(Um)/Somme(exp(U)). Où Um est l'utilité d'un mode particulier pour un individu et vaut une combinaison linéaire de poids et critères comme le coût, le temps,... Ces poids sont déterminés par régression à partir des données socio-démographiques. L'auteur se contente pour son modèle d'exemple d'appliquer une pondération du nombre de trajets par la proportion estimée de chaque mode.

## 1.8 Etape 4 : Route Choice

La dernière étape consiste à assigner chaque trajet modalisé à un lien particulier du réseau de transport par la méthode de Franck-Wolfe dite de "l'User Equilibrium. Cette méthode consiste simplement à calculer une première estimation de trafic dite "all-or-nothing", c'est-à-dire où chaque utilisateur prend le trajet le plus court. Cela permet d'estimer la congestion et ainsi de mettre à jour les temps de trajet. Une seconde itération AON est ainsi effectuée avec les temps de trajets mis à jour et le processus est répété jusqu'à ce qu'il converge.

## 1.9 Rétroaction du modèle

Ce processus de réitération est à distinguer de la rétroaction du modèle. Le processus de réitération de l'étape 4, considère comme extrinsèque la demande en transport et ne la modifie pas. Le FSM introduit des boucles de rétroaction en réinjectant l'état du trafic calculé dans le calcul de l'étape 2 et/ou 3. Cela permet de mettre à jour l'impédance entre deux cellules et donc les matrices O/D (étape 2), ainsi que le choix de mode (étape 3). L'auteur précise que cette rétroaction n'a pas de garantie formelle de convergence.

## 1.10 Limites du modèle pour notre sujet

Le modèle FSM est sujet à de nombreuses limites. La plus importante d'entre elles étant probablement la considération de l'offre de transport et des lieux d'activité comme extrinsèques au modèle. Ainsi, le modèle est incapable de prendre en compte le fait que l'augmentation de l'offre de transport s'accompagne généralement d'une augmentation des temps de trajet et d'une relocalisation des individus plutôt que d'une décongestion du traffic. Cela rend ce modèle relativement adapté à étudier le trafic à partir d'enquêtes socio-économiques mais il nous semble plus douteux de l'utiliser pour étudier l'évolution

du trafic dans le cadre d'un changement important de l'offre de transport, comme la réouverture d'une voie ferrée. Enfin, il nous semble qu'une lacune de ce chapitre est de ne pas s'attarder sur les possibilités de validation de tels modèles. La validation nous semble particulièrement importante pour ne pas que le modèle soit arbitraire et puisse simplement conforter la vision particulière d'aménageur. Elle nous semble également d'autant plus important qu'il apparaît ardu de la réaliser, dans la mesure où les données précises sur le trafic ne sont pas faciles à obtenir.

# Chapitre 2
# Matériel et méthodes

## 2.1 Sources de données

### 2.1.1 Les données de mobilité

Pour ce projet, nous nous sommes appuyés sur les données de l'INSEE. Nous utilisons les jeux de données Mobilités professionnelles et Mobilités scolaires. Nous avons ainsi les déplacements avec la commune de départ et d'arrivée. Le jeu de données Mobilités scolaires n'a pas l'information du mode de transport utilisé donc il n'a finalement pas été utilisé.

### 2.1.2 Les données vecteur

Nous récupérons les données de chemin de fer sur le portail de la SNCF Open Data. Une première couche comprend l'information du statut de la ligne (exploitée, déclassée, vendue...) et une deuxième correspond aux vitesses sur chaque tronçon de ligne.

## 2.2 Zone d'étude

Pour choisir notre cas d'étude, nous nous sommes appuyés sur le rapport "Propositions pour un Plan National de Réouverture des Lignes Ferroviaires" de la FNAUT (Broucaret et al., 2025), qui liste les lignes ferroviaires désaffectées identifiées par cette fédération comme les plus pertinentes à réouvrir. Nos critères pour la sélection du choix d'étude étaient :

1. Que la ligne concerne essentiellement des trajets domicile/travail, ce qui permet de garder une aire d'étude restreinte et d'exploiter les données sur les trajets domicile/travail de l'INSEE.
2. Que la ligne ne serve pas à connecter la zone d'étude à des métropoles lointaines.
3. Que la ligne ne concerne pas une métropole importante, dont les comportements de transport seraient trop compliqués à modéliser.

La ligne ferroviaire désaffectée respectant le plus ces critères parmi celles proposées par la FNAUT était la ligne Troyes/St-Florentin-Vergigny, qui permet de réaliser une liaison ferroviaire entre Troyes et Auxerre.

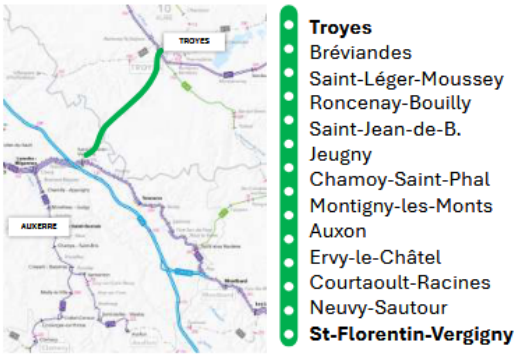



FIGURE 2.1 – Ligne de la potentielle réouverture retenue

Un des avantages de cette ligne est qu'elle suit exactement le trajet de la Nationale 77, qui est réputée saturée selon la FNAUT. Cette situation semble être un terrain propice à estimer des reports modaux voiture/train, puisque la saturation de la route rend vraisemblable le report vers le train et que le graphe de transport est ici très simplifié par la présence de ce grand axe unique pour les voitures. En outre, cette ligne connecte deux villes moyennes entre elles et n'a pas vocation à les relier à de grandes métropoles, aux graphes de transport complexes.

### 2.2.1 Définition de la zone d'étude

Maintenant que la ligne ferroviaire est choisie, il nous faut définir précisément la zone géographique retenue. Les données de la base mobpro dont nous disposons sont à l'échelle de la commune. Nous souhaitons donc que notre zone d'étude soit composée de communes. Nous souhaitons que notre zone d'étude soit à la fois restreinte géographiquement, pour garder un cas relativement simple et que la proportion la plus importante possible de trajets domicile/travail ayant lieu dans cette zone soit internes à cette zone. Sur les conseils de Monsieur Raimbault, nous sommes partis des aires d'attraction des villes définies par l'INSEE. Ces aires sont définies en identifiant d'abord des centres, à partir de seuils de densité de population et d'emplois sur les communes. Ensuite, toutes les communes envoyant plus de 15% de ses actifs dans un centre sont agrégées à l'aire d'attraction de ce centre.

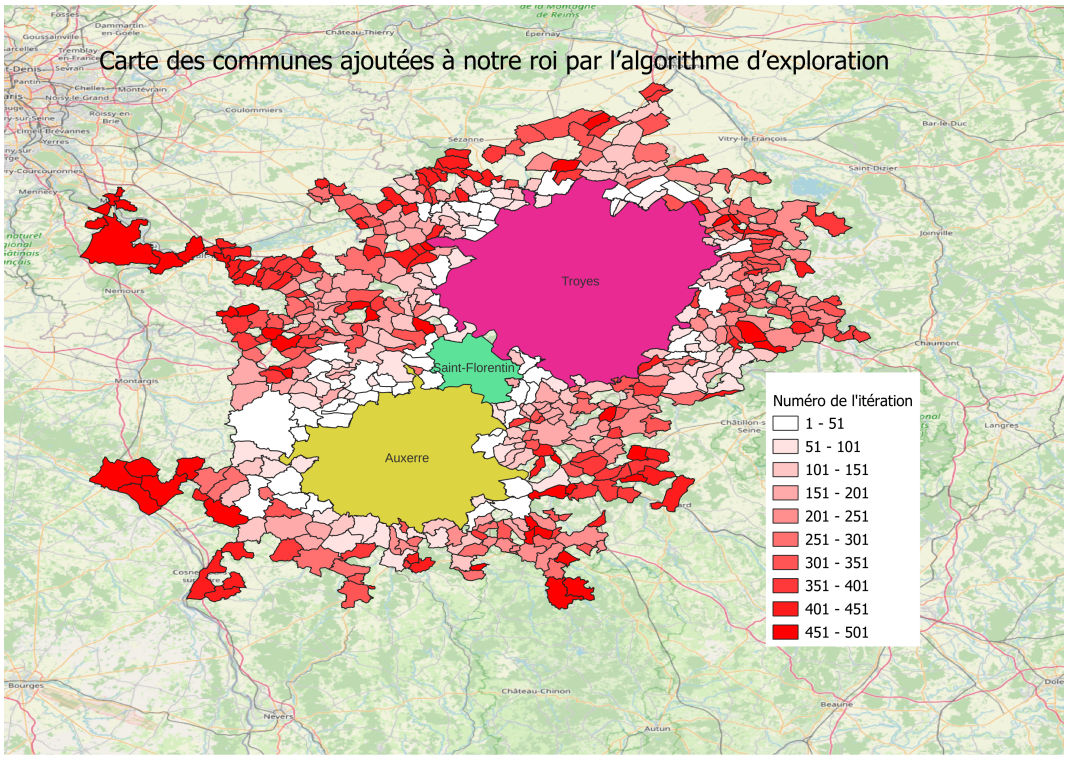
Cette base d'interconnectivité dans la définition des aires d'attraction nous permet déjà de garantir une bonne proportion de trajets domicile/travail internes à notre aire. Notre ligne ferroviaire permet de connecter trois villes ayant une aire d'attraction : Troyes, St-Florentin-Vergigny et Auxerre. Nous avons donc choisi comme zone d'étude, l'agrégat des aires d'attraction de ces trois villes.

### 2.2.2 Calcul des pourcentages de trajets internes à notre zone d'étude

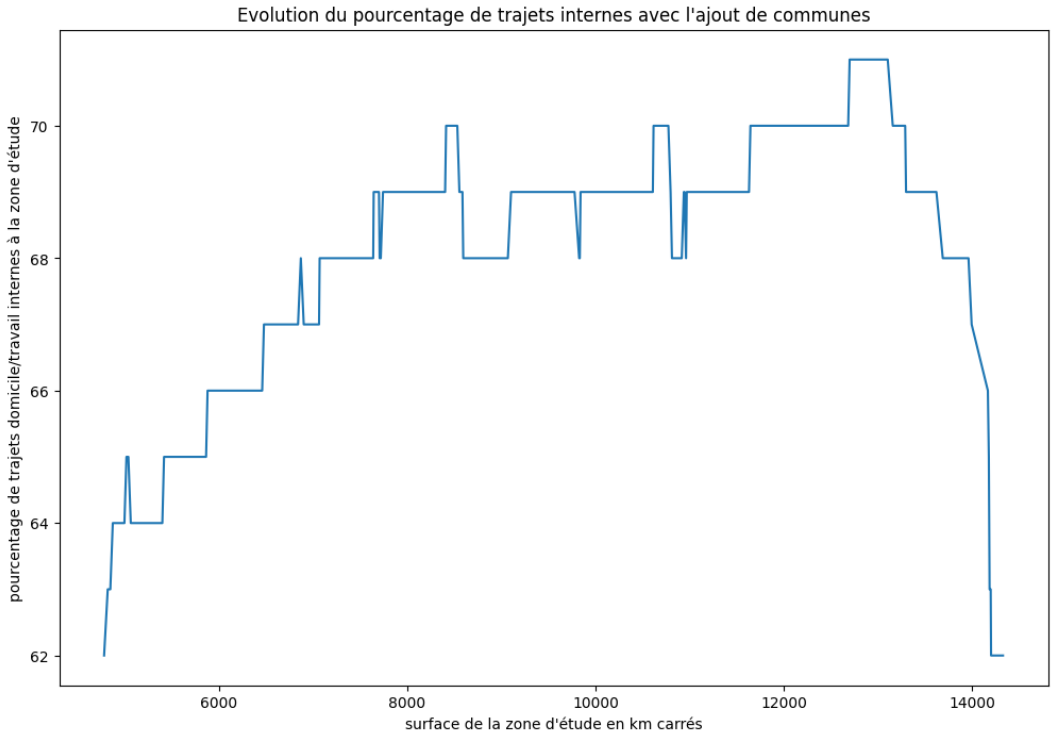
Pour étudier la pertinence de notre zone d'étude, nous avons utilisé deux algorithmes pour comparer sa proportion de trajets internes à celle d'autres zones plus larges.

### Premier algorithme d'exploration des zones d'étude

Le premier algorithme correspond à la première implémentation de la fonction explore_roi dans le fichier etude_aav.sql de notre dépôt git.
Celui-ci prend notre zone d'étude en entrée et y ajoute la commune limitrophe ayant le plus de trajets domicile/travail provenant ou allant dans notre zone d'étude. Il recalcule ensuite la proportion de trajets internes à cette nouvelle zone. L'algorithme répète cette opération un nombre arbitraire de fois.
Nous avons testé cet algorithme avec 500 itérations et obtenu les résultats ci-dessous :
On peut voir sur la figure 2.2b que la proportion de trajets internes à notre ROI commence à 62% et augmente d'abord assez vite, par rapport à l'augmentation de la surface de ROI, avant de se stabiliser autour de 70%. A partir de 13000 km2 environ, le pourcentage chute de nouveau. Cette analyse montre que nous aurions pu ajouter quelques communes à notre ROI et augmenter notre pourcentage de trajets internes, tout en gardant une aire relativement restreinte et pertinente pour étudier le report modal sur notre ligne de train uniquement.




(a) Cartographie des communes dont l'ajout a été considéré par l'algorithme en fonction de l'itération correspondante




(b) Evolution du pourcentage de trajets internes en fonction de l'augmentation de la surface du ROI

### Deuxième Algorithme d'Exploration des Zones d'Etude

Dans le même code SQL que précédemment, nous avons implémenté une deuxième version de l'algorithme d'exploration des zones d'étude. Ce deuxième algorithme, plus ambitieux, prend comme critère pour classer les candidats à l'insertion dans la zone d'étude le ratio entre le nombre de trajets internes à destination ou provenant de notre ROI ou de trajets internes à la commune elle-même et le nombre de trajets totaux venant de ou terminant dans cette commune. Nous avons également calculé la population du ROI, plutôt que sa surface. En outre, cet algorithme est capable d'ajouter soit une commune soit toute une aav, en fonction laquelle a le ratio le plus grand à une itération particulière de la boucle. Cependant, cet algorithme n'a donné aucun résultat pertinent, notamment parce qu'il a très rapidement intégré Paris au sein du ROI et ainsi grandement faussé l'étude. La ligne droite sur le graphique ci-dessous correspond au moment où Paris est intégrée à notre zone d'étude, ce qui fait énormément bondir la population et rend inutile l'algorithme.

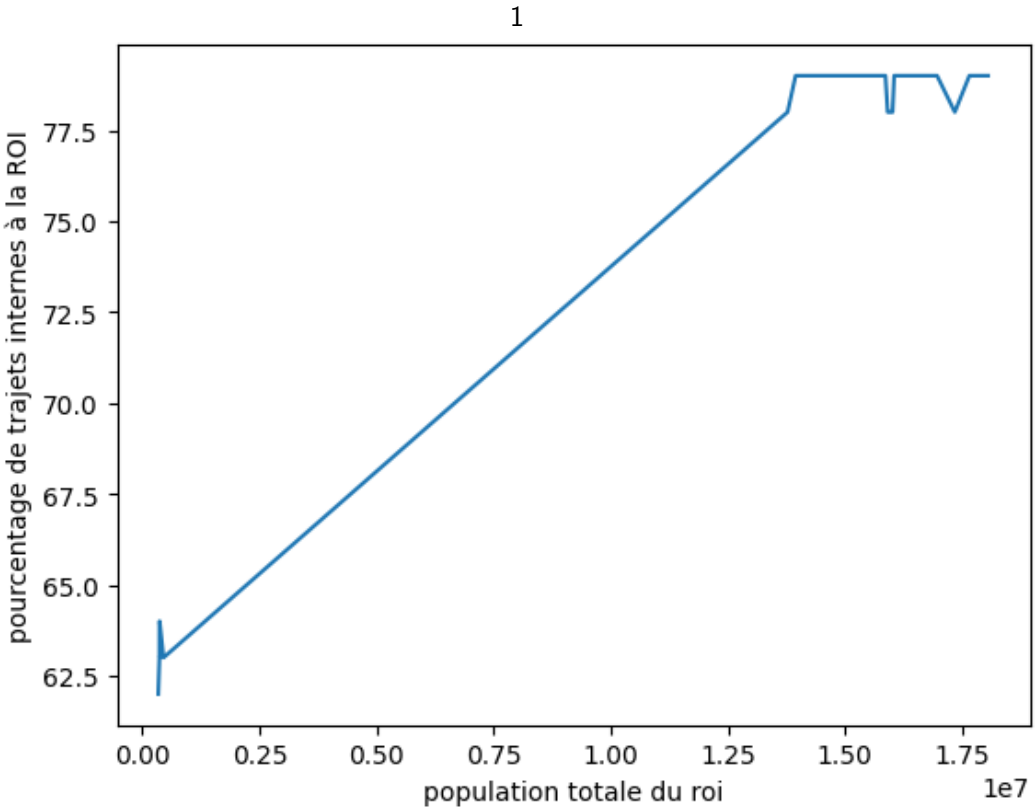



FIGURE 2.3 – Evolution du pourcentage de trajets internes en fonction de l'augmentation de la population du ROI

# Chapitre 3 Traitement des données

Pour ce projet, une base de données partagées a été créée via Pg Admin. Cela a rendu plus simple les traitements effectués par chacun.

## 3.1 Création des graphes

### 3.1.1 OSMnX

Pour avoir les graphes routier, piéton et vélo, nous utilisons la bibliothèque OSMnx construite sur NetworkX. Cela nous permet de récupérer les graphes sur l'ensemble de notre zone.
Une fois les graphes récupérés, nous calculons la vitesse. La méthode diffère selon le type de graphe. Pour le graphe routier, nous nous basons sur la vitesse indiquée dans speed_max et au besoin au type de route. Pour les deux autres graphes, nous regardons le type de route pour déterminer si c'est une route praticable en vélo ou à pied. Par exemple, nous écartons les autoroutes ou les routes nationales en leur attribuant une vitesse très faible. Avec la vitesse, nous calculons le temps de trajet pour chaque arête. Nous obtenons ainsi un graphe pondéré.
Par souci de nomenclature, les colonnes créées sont nommées de la même façon que si nous avions utilisé les fonctions d'OSMnx pour les calculer.
Le choix a été fait de ne pas utiliser les fonctions natives d'OSMnx car les vitesses obtenues ne nous paraissaient pas satisfaisantes. Cela ne permettait pas de faire une différence selon le mode de transport et les vitesses étaient les mêmes que la personne soit à pied, à vélo ou en voiture.

### 3.1.2 Le graphe ferroviaire

Pour les trains, il fallait construire le graphe à partir des données de la SNCF. Nous récupérons deux couches de lignes, une contenant le statut des lignes (exploitée, fermée, vendue...) et l'autre la vitesse sur les tronçons. La première couche étant plus complète, nous cherchions à associer l'information de vitesse sur les tronçons de "statut". Cependant, l'appariement des données n'a pas pu se faire. En effet, le découpage varie entre les deux couches. Les couches ne sont donc pas superposées en termes de tronçons. En outre, elles sont décalées spatialement à certains endroits. Elles ne correspondent pas exactement en termes de segment et de superposition spatiale. Ici, sur l'image 3.1, sur la ligne Paris-Monts, les deux vecteurs représentent la même entité du monde réel mais ne sont pas superposées. L'appariement aurait donc été trop compliqué à mettre en place dans le temps imparti.

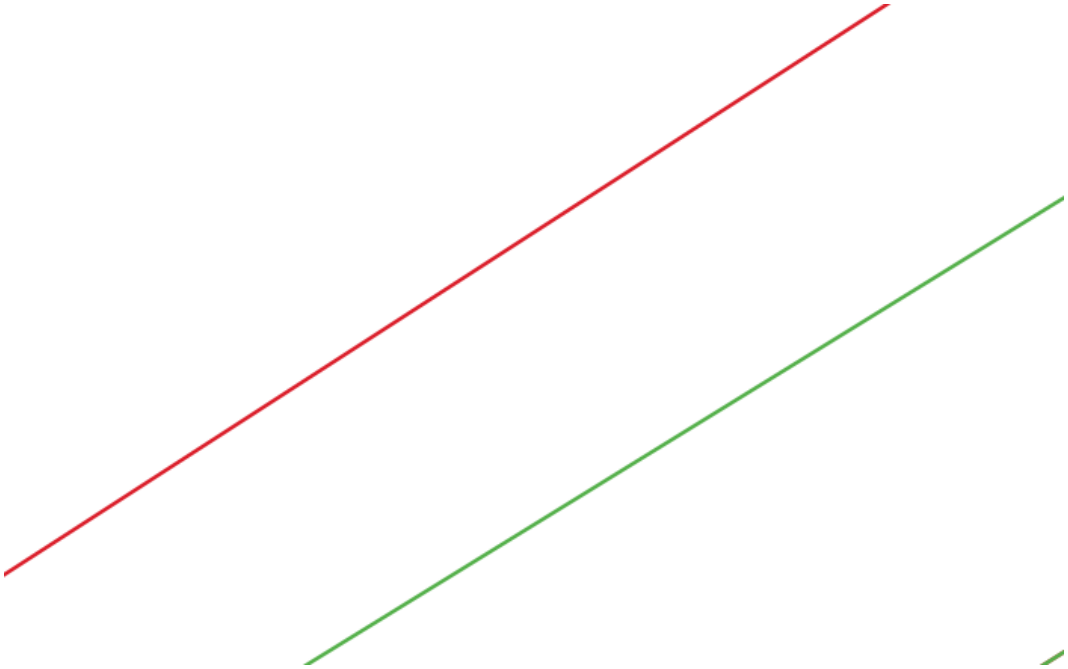


FIGURE 3.1 – La couche statut en rouge et la couche vitesse en vert pour la ligne 431000 tronçon 1

Ainsi, nous avons fait le choix de mettre une vitesse constante sur notre zone en partant du principe que ce sont surtout des TER qui sont utilisés à cet endroit et la ligne qui nous intéresse concerne les TER. Ces trains ont une vitesse comprise très souvent entre 100 et 160 km/h. Nous avons donc choisi une vitesse de 120 km/h pour l'ensemble des lignes de notre zone car la ligne est plutôt sinueuse.

Il faut transformer cette couche en graphe connexe et ajouter les gares comme nœuds.

Ensuite, il faut relier le graphe au graphe piéton.

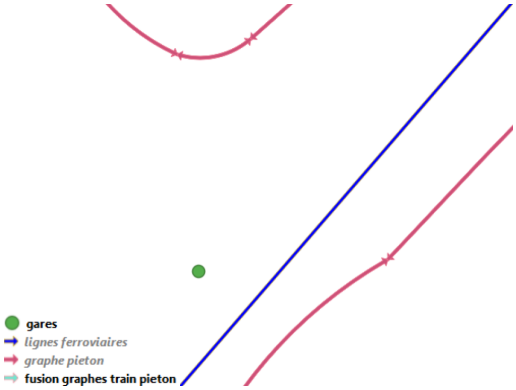
## 3.2 Matrice OD

Pour chaque mode de transport, une matrice Origine Destination est créée sur les communes internes à notre zone.

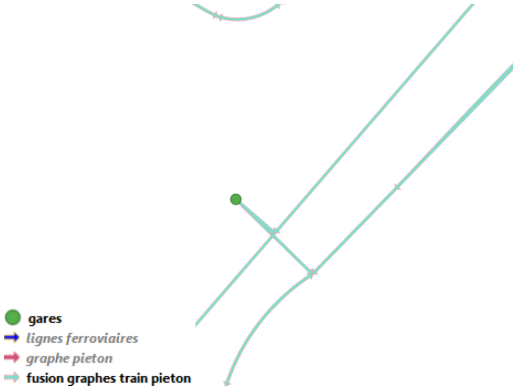
Pour chaque couple origine/destination, on regarde le nombre de personne qui emprunte cette combinaison. La population concernée est extrapolée à partir de l'effectif de l'échantillon, de la population active de la commune d'origine et de la taille de l'échantillon.

Pour la matrice od_drive, le choix a été fait de rassembler tous les véhicules personnels motorisés à la fois deux-roues, voiture et camion...

Pour la matrice od_train, nous nous concentrions sur les trajets avec le mode "transports en commun" déclaré. Cela couvre d'autres modes de transport que le train mais il n'existe pas de données plus fines pour ce jeu de données.




(a) gare et graphes piéton et ferroviaires d'origine




(b) gare et graphes piétons et ferroviaires fusionnés

## 3.3 Fusion des Graphes

Les algorithmes que nous utilisons dans le chapitre suivant, consacré à la modélisation du trafic, utilisent l'algorithme A* pour calculer les chemins empruntés par les individus pour aller de la commune de départ à la commune d'arrivée. Pour modéliser le trajet des individus prenant le train, nous avons pris le parti d'utiliser également cette méthode. Une autre approche, que nous n'avons pas eu le temps d'implémenter, aurait consisté à chercher les gares les plus proche de la commune de départ et d'arrivée, et calculer les temps de trajet correspondants et le temps de trajet gare à gare en train et à additionner ces trois temps. Nous avons plutôt choisi de fusionner les graphes, c'est à dire connecter les graphes piétons et vélo au graphe ferroviaire, *via* les gares.

Cela implique un traitement algorithmique assez fastidieux, que nous avons implémenté dans les fonctions split_and_add et add_nodes du notebook fusion_graphes.ipynb du dépôt github de ce projet. Pour deux graphes G1 et G2 à fusionner *via* les points P, le traitement consiste à :

- pour chaque point P, récupérer le segment de G1, qui en est le plus proche.
- récupérer pour chaque segment ainsi trouvé, la liste de toutes les gares qui en sont les plus proches.
- découper chacun de ces segments selon la projection de l'ensemble des points qui en sont les plus proches sur ce segment.
- ajouter ces segments au graphe, et supprimer les anciens segments.
- un segment connectant la gare au graphe.
- faire la même chose pour G2
- concaténer les noeuds et arrêtes de G1 et G2.

Avec les graphes piétons/trains et vélos/trains, nous pouvons directement calculer des plus courts chemins d'une origine à une destination. Cela permet de modéliser le fait que les individus se rendent à pied ou à vélo à une gare pour y prendre le train. La limite de cette méthode est qu'il est impossible de modéliser la multimodalité voiture/train. En effet, il est relativement acceptable de fusionner les graphes piétons ou vélo avec le graphe de train car les vitesses de ces modes de transport sont très différentes. Si on fusionne le graphe de voiture et de train en revanche, on trouvera des trajets de longue distance intégralement en voiture. La méthode que nous avons retenu est donc une approximation, et si nous avions plus de temps, il serait préférable d'implémenter la

méthode de somme de trois distances sur deux ou trois graphes différents décrite plus haut.

# Chapitre 4 Modélisation du report Modal

## 4.1 Modélisation du Trafic Actuel Dans notre zone d'étude

Nous avons commencé par estimer le trafic sur chaque arête de nos graphes de transport, à partir des matrices Origine/Destination.
Le script mis au point constitue le notebook `calcul_traffic_niveau1.ipynb` du dépôt github de ce projet.

### 4.1.1 Modélisation du Trafic Routier

Nous avons commencé par récupérer la matrice origine/destination des trajets internes à notre ROI et restreints aux transports motorisés (codes 4 et 5 de la colonne TRANS de la base mobpro). Nous avons ensuite fait l'hypothèse que la proportion

$$\frac{e_{od}}{e_o} = \frac{pop_{od}}{pop_o}$$

avec :

- $e_od$ l'effectif d'enquêtés de la base mopro déclarants faire ce trajet origine/destination.
- $e_o$ l'effectif d'enquêtés de la base mobpro déclarants habiter dans la commune origine.
- $pop_{od}$ le nombre réel d'individus faisant ce trajet domicile-travail.
- $pop_o$ la population active habitant dans la commune d'origine de ce trajet.

Nous avons ainsi approximé $pop_{od} = \frac{e_{od}}{e_o} \times pop_o$.

#### connexion communes/graphes

Nous avons besoin de trouver une manière de connecter les communes au graphe routier, pour chercher ensuite des chemins reliant les communes d'origine et de destination de notre matrice.
La littérature et en particulier McNally, s. d., mentionne le fait que cet appariement est généralement fait en prenant le noeud du graphe de transport le plus proche du centroïde de chaque unité spatiale, dans notre cas la commune. Cette méthode nous a semblé inadaptée à notre projet pour deux raisons :

- Les approches mentionnées dans la littérature disposent d'unités spatiales plus fines que la commune pour la description des trajets origine/destination. L'approximation aux centroïdes est donc moins grave.
- Notre cas s'intéresse au report modal du train. Or, les gares étant peu nombreuses, prendre un noeud représentatif d'une commune avec un critère trop arbitraire, fait courir le risque de beaucoup surrestimer le temps de trajet en train.

Nous avons ainsi choisi de prendre comme noeud représentatif de chaque commune un noeud fortement connecté et non isolé dans le graphe de transport particulier que nous étudions.
Pour cela, nous avons pris comme critère l'indice de centralité de proximité. Pour rappel, l'indice de centralité de degré d'un noeud donne le nombre d'arêtes connectées à ce noeud, l'indice de centralité d'intermédiarité donne le nombre de plus courts chemins sur le graphe passant par ce noeud, et l'indice de centralité de proximité d'un noeud est l'inverse de la moyenne des distances les plus courtes entre ce noeud et tous les autres noeuds du graphe.
Notre hypothèse était donc qu'en prenant des noeuds avec un haut score de centralité de proximité, nous serions plus représentatifs des véritables temps de trajet, en particulier les temps de trajet en train.
Cependant, l'indice de centralité de proximité est extrêmement intensif en calcul et il est impossible de le calculer pour chaque noeud de graphes aussi importants que le notre. Pour déterminer le noeud représentant de chaque commune en essayant malgré tout de sélectionner des noeuds avec de bons indices de proximité, nous avons donc appliqué la méthode suivante :

- pour chaque commune de notre ROI, on tire au hasard 30 noeuds de notre graphe.
- on récupère le sous-graphe de notre graphe de transport, constitué uniquement de ces noeuds tirés aléatoirement.
- on calcule l'indice de proximité de chaque noeud seulement au sein du sous-graphe.
- on détermine le représentant de chaque commune comme le noeud ayant le plus fort indice de proximité, calculé selon cette simplification

Une fois obtenue une matrice noeud d'origine / noeud de destination grâce à cette méthode, nous avons calculé les plus courts chemins entre ces noeuds avec l'algorithme A* et une heuristique euclidienne. L'algorithme A* est similaire à l'algorithme de Dijkstra mais ordonne sa queue d'évaluation des noeuds, non pas simplement en fonction de la distance entre ce noeud et le noeud actuel mais en fonction de cette distance plus une distance heuristique entre ce noeud et le noeud d'arrivée. Pour que l'algorithme soit exact, c'est-à-dire qu'il trouve bien le plus court chemin, il faut pouvoir garantir que la distance heuristique soit inférieure ou égale à la distance réelle entre le noeud et la destination. Nous nous sommes contentés d'une heuristique euclidienne, qui est moins efficace pour diminuer le temps de calcul que d'autres heuristiques plus complexes à obtenir mais qui permet déjà d'accélérer le calcul par rapport à Dijkstra, en incitant l'algorithme à ne pas évaluer des noeuds situés à l'opposé du noeud de destination.
Nous avons ainsi obtenu la modélisation du trafic sur notre graphe routier ci-dessous. Cette modélisation est assez cohérente avec ce à quoi on pourrait s'attendre. En particulier, on voit que la fréquentation est forte dans le coeur de Troyes et Auxerre. On voit également que l'axe Troyes/St-Florentin/Auxerre, correspondant à la N77 est relativement fréquenté. Or c'est l'axe qui borde la ligne ferroviaire dont nous avons choisi de modéliser la réouverture. Cela laisse supposer qu'il pourrait en effet y avoir une demande pour cette ligne, en l'état actuel des trajets domicile-travail.

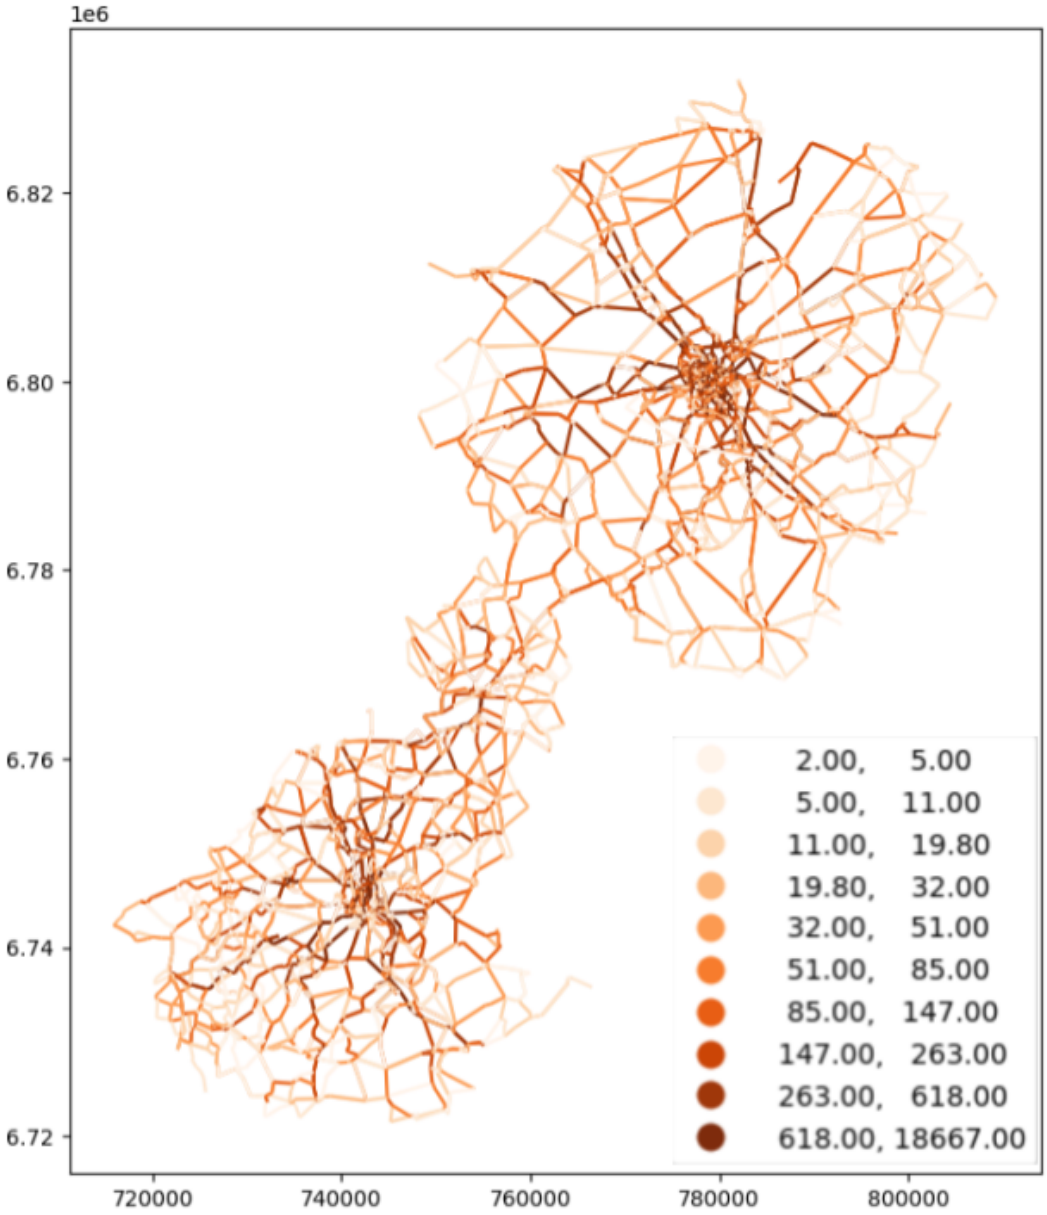



FIGURE 4.1 – Le graphe routier en fonction du passage sur chaque arc

### 4.1.2 Modélisation du Trafic Ferroviaire

La méthode utilisée pour le graphe ferroviaire est assez similaire à celle pour le graphe routier. Nous cherchons les plus courts chemins pour chaque couple de noeuds origine/destination de la matrice OD du train.

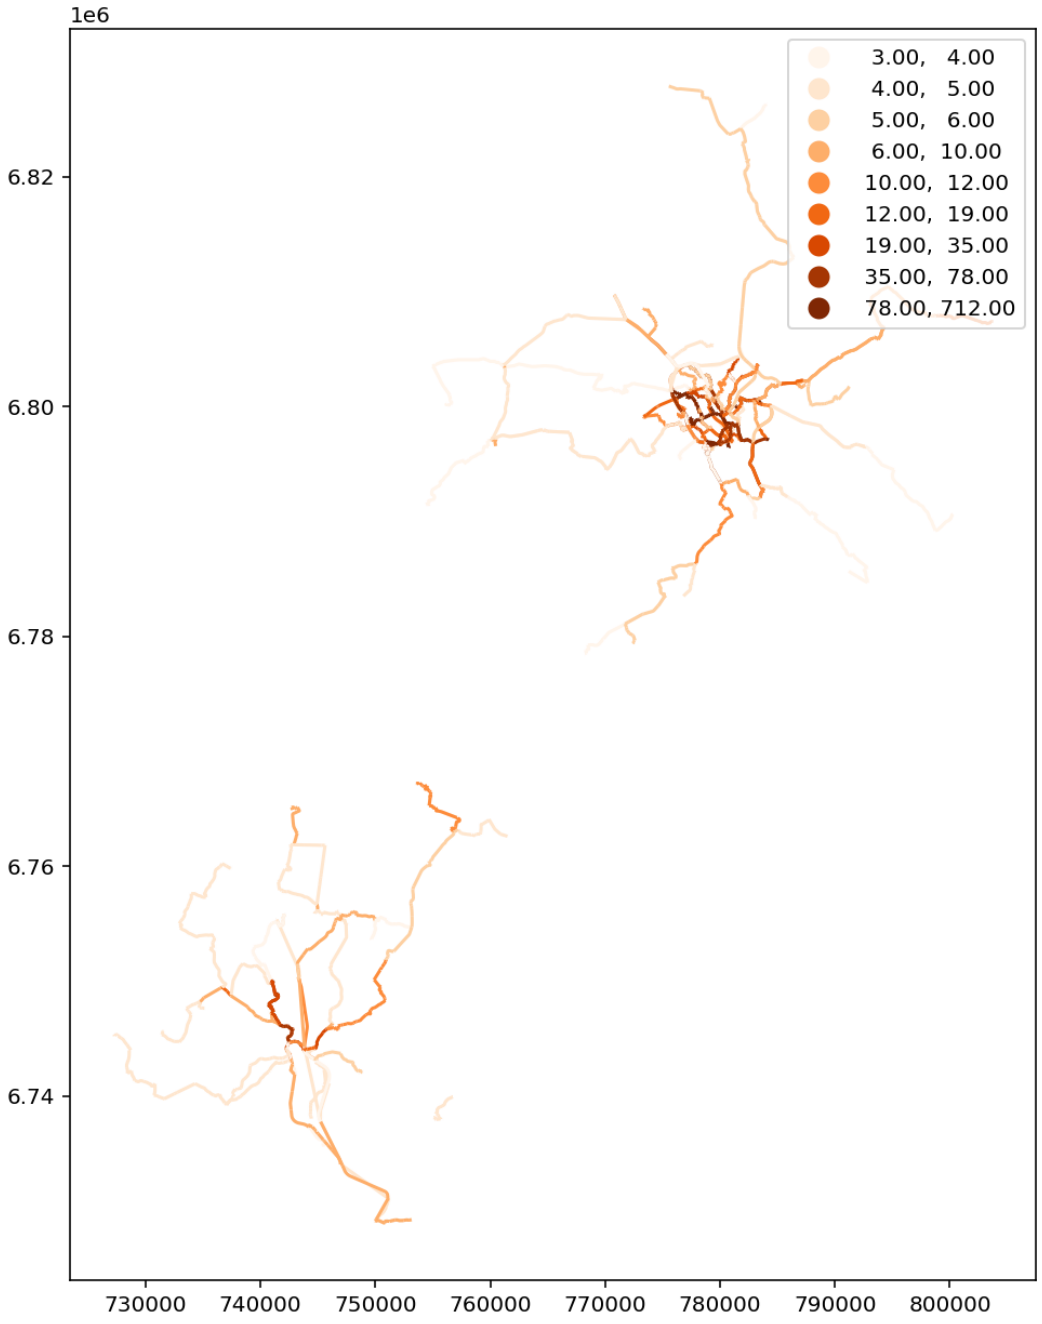



FIGURE 4.2 – Le graphe ferroviaire en fonction du passage sur chaque arc avec ici seulement les lignes encore en activité

En comparant ce résultat avec le graphe train_pieton, on peut voir que certaines arêtes

correspondent à une ligne de train. La plupart de ces déplacements se font via les routes ce qui est dû au fait que les données de l'INSEE de mobilité professionnelle comptabilise le train dans la catégorie transports en commun ce qui inclut aussi le bus. On peut donc supposer que ce sont ces trajets qui sont représentés malgré le poids des arêtes correspondant à la marche.

## 4.2 Modélisation du Report Modal par Implémentation d'Hypothèses

Dans son rapport, la FNAUT mentionne quatre lignes qui ont réouvert depuis 2000 :
- Cannes-Grasse,
- Avignon-Carpentras,
- Nantes-Chateaubriant,
- Tours-Chinon

Ici, c'est la dernière connexion qui va nous intéresser, de par sa forte ressemblance avec notre cas d'étude. Les deux lignes sont des substituts directs parallèles d'une route saturée liant les deux destinations. Les villes également ont des ressemblances, la première est une grande ville attractive, la seconde est une petite ville, dont la plupart de ses habitants rejoignent la grande ville en question à proximité pour travailler.
C'est en 1981 que la SNCF ferme cette ligne au trafic de voyageurs. Pour compenser cette fermeture, le trafic est déplacé sur la route, via une desserte de bus plus importante que la précédente offre ferroviaire, en empruntant la D751, parallèle à la voie. Dès les premiers mois, la fréquentation chute de plus de 25% par rapport au train, tout en causant une explosion du trafic sur la D751. La conclusion est évidente, on parle presque de report modal vers la voiture.
Suite à des pressions locales des voyageurs, comme des élus, la SNCF rouvre la ligne seulement 18 mois après l'avoir fermée, avec cependant, une offre fortement dégradée par rapport à la disponibilité avant fermeture. Malgré cela, la fréquentation du train est quasiment revenue à la normale, même si l'offre est bien plus réduite, prouvant donc que l'offre ferroviaire est capitale pour des petites villes.
Depuis une dizaine d'années, l'offre et la fréquentation ont presque doublé à Chinon comme dans les villes à proximité comme Azay-le-Rideau. Il est important de rappeler que sur cette période, aucune infrastructure n'a été améliorée ou altérée par rapport à sa situation avant fermeture. C'est donc une excellente opération économique pour la SNCF. En 2021, la ligne a été modernisée et l'offre une nouvelle fois augmentée, résultant en une augmentation de plus de 62% en 2024.
Ce cas de réouverture de ligne est un excellent exemple de report modal vers le train. Même s'il est un peu particulier, car la fermeture n'aura duré que quelques mois, il nous montre que le report modal vers le train est possible même quand un trajet équivalent existe en voiture. Les différentes réouvertures du XXIe siècle, soulevées par la FNAUT, ont également vu une forte augmentation du trafic ferroviaire, avec souvent un nombre de voyages par jour qui a doublé.
En prenant en compte cette réouverture et en l'appliquant à notre étude, nous pouvons estimer qu'environ 10% de la population serait susceptible de prendre le train dans ses trajets quotidiens.
Également, on remarque que, dans le cas des lignes rouvertes, une zone d'influence d'environ 2 à 4 kilomètres autour se forme. On peut donc estimer que la grande majorité

des potentiels utilisateurs de la nouvelle ligne, se trouve dans cette zone. C'est pourquoi nous calculons des zones d'influences de différentes tailles autour des gares pour simuler leur attractivité.

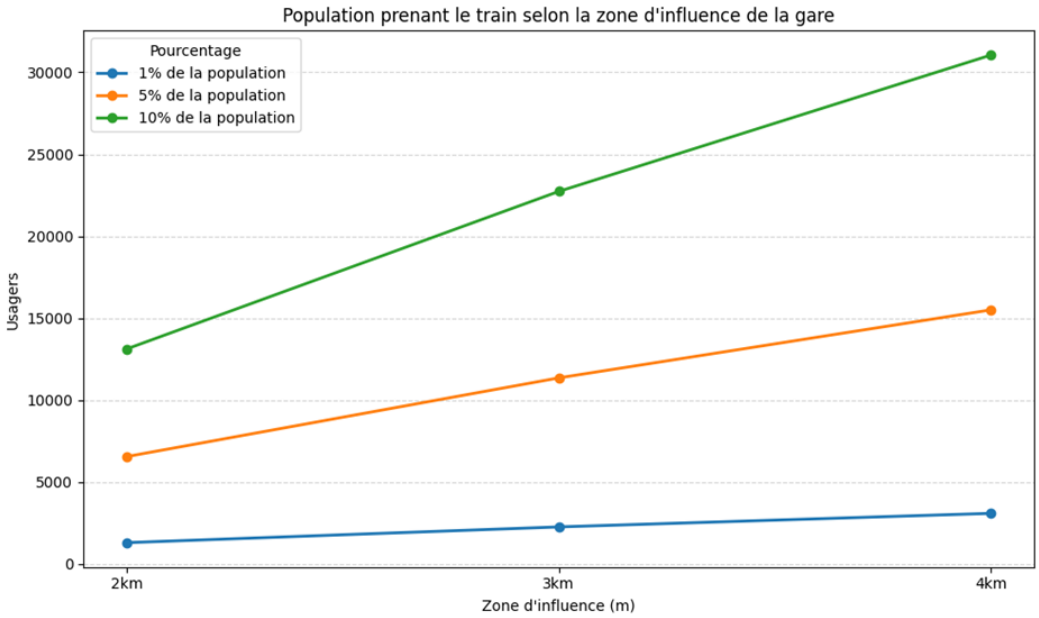



FIGURE 4.3 – Graphique représentant la population susceptible de prendre le train en fonction de l'aire d'influence de la gare

Ce graphique montre exactement ce phénomène. On remarque globalement une tendance à la hausse, assez logique à la vue des tendances des autres lignes. On remarque également que les deux facteurs ont une forte importance sur le nombre de nouveaux voyageurs sur la ligne, mais qu'également, un pourcentage minimum de la population est attendu pour voir un résultat important. En-deçà de 5% le projet de réouverture d'une ligne perd du sens.

## 4.3 Modélisation du Report Modal par Choix Discret

### 4.3.1 Modèle de choix discret et maximisation de la log vraisemblance appliqués à notre sujet

Dans le premier niveau de notre modélisation du trafic sur une ligne de train réouverte, nous avons imposé nous-même des règles de choix de mode de transport. Une autre approche pour déterminer le choix modal, typique de l'étude des transports et notamment présentée dans ! ! !citer chapitre FSM ! ! !, est l'approche dite des choix discrets modélisés par probabilité logistique. Cette approche prend le parti de considérer les individus comme des agents rationnels cherchant à maximiser leur utilité, qui arbitrent leur choix modal en fonction de paramètres dont ils ont parfaitement connaissance. Partant de ce postulat, cette approche consiste à déterminer *a priori* ces paramètres qui président au choix des transports des individus.

Dès lors, dans cette approche, on considère l'utilité procurée par le choix d'un mode de transport comme une combinaison linéaire de ces paramètres d'entrée et de coefficients de préférences :

$$U = \sum_i a_i \times x_i$$

avec $a$ les coefficients de préférence et $x$ les paramètres d'entrée.
Dans notre projet, nous n'avons sélectionné, comme paramètres d'entrée, que le temps de trajet $t$ et le coût monétaire $c$.
On appelle un "segment" un trajet particulier dans notre matrice de trajets domicile travail, qui peut être emprunté par plusieurs personnes. Pour tenir compte du fait que les préférences des individus différent et que pour un même trajet, tout le monde ne prenne pas le même mode de transport, la modélisation en probabilité logistique calcule le choix d'un mode de manière stochastique, comme une probabilité

$$P_m^s = \frac{e^{U_m^s}}{\sum_{i=0}^{n} e^{U_i^s}}$$

où

- $P_m^s$ est la probabilité de choisir un mode m pour le segment s.
- $U_m^s$ est l'utilité procurée par le choix du mode m pour parcourir le segment s.
- $\sum_i U_i^s$ est la somme des utilités de tous les modes pour ce segment

Nous avons à notre disposition la matrice Origine Destination des trajets domicile travail, issus de l'enquête INSEE ! ! !citer spe contenu mobpro ! ! !. Cette matrice nous permet d'avoir le nombre de trajet pour chaque segment et mode $N_m^S$. La logique de cette modélisation consiste ainsi à trouver le vecteur de coefficients

$$\Theta = \begin{bmatrix} a_0 \\ \vdots \\ a_n \end{bmatrix}$$

, avec n le nombre de paramètres de notre modèle, tel que la probabilité d'obtenir la distribution effectivement observée dans l'enquête INSEE soit maximale. On cherche donc à maximiser la fonction nous donnant la probabilité d'obtenir la distribution observée en fonction de nos coefficients de préférence. Cette fonction s'appelle la vraisemblance et se note $L$.
On peut commencer par déterminer $L_s$, la vraisemblance pour chaque segment. Cette fonction est la probabilité d'obtenir une certaine distribution à partir de nos probabilités multinomiales $P_m^s$. On peut donc la déduire de la formule de la probabilité d'une distribution multinomiale. On note $X = \begin{bmatrix} k_1 & \dots & k_m \end{bmatrix}$ le vecteur des effectifs observés pour chaque issue possible de la variable. Dans ces conditions, la probabilité que n tirages d'une variable suivant une loi multinomiale aboutisse à la distribution $X$ se calcule selon la formule :

$$P(\hat{X} = X) = \frac{n!}{\prod_i k_i!} \prod_i p_i^{k_i}$$

avec $p_i$ la probabilité du choix du mode $i$

Dans notre cas, on a vu la formule de la probabilité de chaque mode pour un segment $P_m^s$ et la matrice Origine/Destination de l'Insee nous fournit les effectifs par mode et par segment, qu'on note $e_m^s$. De là, on a :

$$L_s(\Theta) = P(\hat{E} = E_{obs}|\Theta) = \frac{n!}{\prod_m e_m^s!} \prod_m P_m^{s^{k_i}}$$

avec $n$ l'effectif total du segment.
De là, en considérant que les probabilités de chaque segment sont indépendantes, on considère que la vraisemblance de l'ensemble des segments est simplement le produit des vraisemblances de tous les segments : $L(\Theta) = \prod_s L_s(\Theta)$.

Notre but est donc de trouver $\theta$ qui maximise la vraisemblance $L$. En économétrie on ne maximise pas la vraisemblance mais la log vraisemblance, car cela permet de transformer les nombreux produits en sommes plus simples, sans changer le maximum de la fonction. la fonction que l'on cherche à maximiser est donc

$$logL = log(\prod_s L_s) = \sum_s log(L_s) = \sum_s log(\frac{n!}{\prod_m e_m^s!}) + log(\prod_m P_m^{s^{k_i}})$$

À ce stade, en économétrie, on ignore le log du coefficient multinomial

$$log(\frac{n!}{\prod_m e_m^s!})$$

La raison avancée est que ce terme ne dépend pas de $\Theta$ mais nous ne maîtrisons pas la démonstration de cela et le prenons comme une donnée pour notre projet. Une fois ignorée ce terme, on arrive donc à la formule étonnamment simple :

$$logL = \sum_s log(\prod_m P_m^{s^{k_i}}) = \sum_s \sum_m logP_m^{s^{k_i}} = \sum logP_m^{s^{k_i}} = \sum k_i logP_m^s$$

La formule des probabilités logistiques permettant d'obtenir les $P_m^s$ étant tout de même très complexe, il n'existe pas de solution analytique pour maximiser cette formule. Nous avons eu recourt pour cette maximisation à l'algorithme scipy.optimize.minimize, qui opère une minimisation computationnelle en calculant empiriquement le gradient de la fonction.

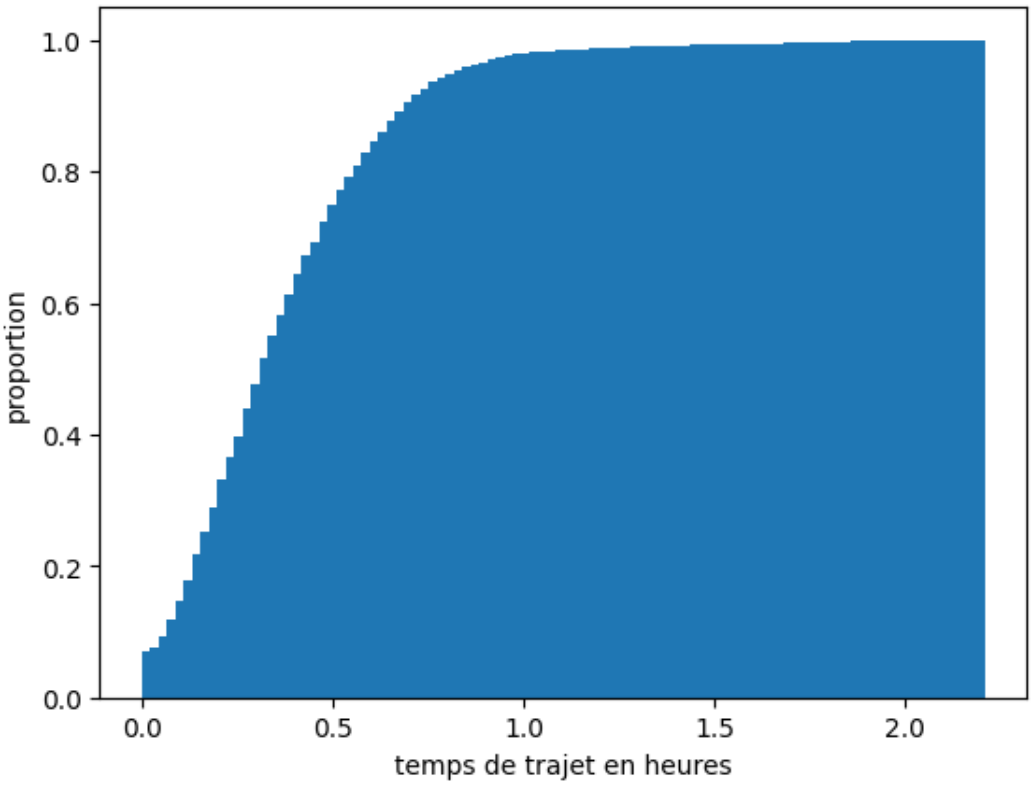
### 4.3.2 Calcul de la matrice des paramètres

Nous avons choisi dans un premier temps de modéliser l'utilité procurée par un mode pour un segment comme une combinaison linéaire du temps de trajet et du coût financier de ce trajet.

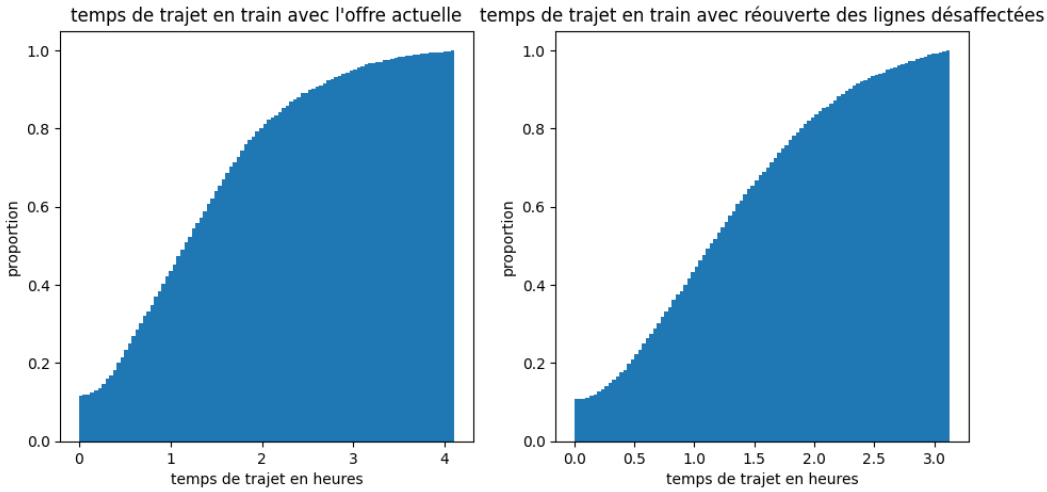
#### Calcul des temps de trajet

Pour calculer les temps de trajet, nous avons procédé selon la même méthode que celle détaillée pour obtenir les plus courts chemins entre une commune d'origine et une commune de destination dans la partie 4.1.

Nous obtenons ainsi les trois histogrammes cumulés ci-dessous représentant les temps de trajet parcourus par des enquêtés mobpro en voiture et en train avec ou sans réouverture des lignes désaffectées. Les temps de trajet en train ont été calculés en supposant une multimodalité train/vélo.
Les histogrammes de train ont été obtenus en excluant les 5 derniers percentiles de temps de trajet, car ceux-ci constituaient des outliers bien trop élevés par rapport à la moyenne.
On peut voir que les temps de trajet sont globalement plus court en voiture qu'en train et sont tous inférieurs à deux heures trente. On peut également voir que les temps de trajet réduisent de manière importante avec réouverture des lignes désaffectées, le maximum passant d'un peu plus de 6 heures à un peu plus de trois heures.
Les temps de trajet valant 0 correspondent aux temps des trajets internes à une même commune, qui sont assez nombreux dans la base mobpro. On aurait pu approximer ces temps par un temps moyen de déplacement dans chaque commune mais cela n'aurait vraisemblablement pas été très utile pour la modélisation de choix discret.
Ces temps de trajet ne sont pas forcément très représentatifs des temps réellement effectués, puisqu'ils ne prennent pas en compte la fréquence des trains et qu'ils résultent d'une approximation de trajet entre deux communes en prenant comme représentant de chaque commune des nœuds considérés comme assez centraux mais quand même tirés en partie au hasard.




(a) Histogramme cumulé des temps de trajet en voiture




(b) Comparaison entre les temps de trajet en train avec ou sans réouverture des lignes désaffectées

### Calcul des coûts financiers

Afin d'estimer le coût d'une voiture, nous avons décidé de comparer différentes dépenses pour les trois voitures les plus présentes sur les routes.
D'après les études d'Autoplus et de l'ARGUS, en 2022, il s'agissait de la Renault Clio 3, et des Peugeot 207 et 208 I. Nous avons donc compilé les dépenses liées au plan d'entretien fourni par le constructeur, l'assurance d'un véhicule immatriculé en juin 2018 et avec les mêmes caractéristiques de conducteur, le contrôle technique et la consommation d'essence par litres au 100km. En se basant sur 225 jours travaillés par an, on obtient ce tableau :

| | Motorisation | Consommation (L/100km) | Année de fabrication | Prix du L d'essence | Cout assurance mensuel (en €) | Cout CT (en €) | Entretien annuel (en €) | Cout Aller (en €) | Cout annuel (en €) |
|---|---|---|---|---|---|---|---|---|---|
| Renault Clio 3 | 1,2L 16V Authentique | 5,8 | 2018 | 1,69 | 41 | 75 | 1600 | 8,17 | 4334,95 |
| Peugeot 207 | PLUS 1,4E 75 | 5,3 | | | 38 | 75 | 1900 | 3,60 | 3835,64 |
| Peugeot 208 I | 1,2L VTI 82 ACTIVE | 4,7 | | | 48 | 75 | 2200 | 4,27 | 4520,03 |

FIGURE 4.5 – Tableau comparatif des coûts des voitures les plus en circulation en France en 2022

En moyenne, le coût d'une voiture est donc d'environ 4000€ par an, même en prenant le minimum dans chaque catégorie. En moyenne, nous avons donc calculé, pour 20 jours travaillés par mois, soit 40 trajets aller :
- CE, une estimation du coût moyen d'entretien d'une voiture : 5.27€/aller
- CD, une estimation du coût de l'essence en fonction de la distance parcourue : 0.08€/km
- CA, une estimation du coût d'amortissement d'une voiture : 2.30€/aller
Si nous comparons ces résultats au coût annuel d'un abonnement de TER pour la même ligne, ce dernier nous coûtera 69.20€ par mois, soit 1.73€ par trajet. Le train coûte donc cinq fois moins cher que la voiture, pour un trajet équivalent. De plus, les coûts de la voiture sont, ici, assez utopiques. Il n'y a aucune prise en compte d'une fluctuation des prix de l'essence, d'une assurance, ou même des coûts liés au parking de la voiture, tous ces facteurs ne feraient qu'augmenter la facture finale.

## 4.4 Détermination des Coefficients de préférence

Nous avons pu obtenir une matrice de paramètres

$$X = \begin{bmatrix} (t,c)_{0,0} & \dots & (t,c)_{0,m} \\ \vdots & \ddots & \vdots \\ (t,c)_{s,0} & \dots & (t,c)_{s,m} \end{bmatrix}$$

avec $s$ le nombre de segments, $m$ le nombre de modes, $t$ le temps de trajet et $c$ le coût économique du trajet, en l'occurrence, nous n'avons retenu que l'alternative véhicules motorisés et transport en commun.
Nous avons ensuite centré réduit cette matrice, ce qui est important pour avoir des coefficients du même ordre de grandeur et également pour rendre la fonction calculable. En effet, la modélisation logit impliquant de prendre l'exponentielle de l'utilité pour choisir le mode, il est important que les valeurs d'utilité soient faibles pour ne pas manipuler des chiffres bien trop grands.

Nous avons également filtré un certain nombre de valeurs. En particulier, nous avons supprimé tous les segments où nous n'avons pas réussi à calculer un temps de trajet, à cause de problèmes de connexité de nos graphes de transport.
Grâce à cette matrice, nous pouvons estimer comme vu précédemment la vraisemblance de notre modèle en fonction des coefficients s'appliquant au temps de transport et au coût. Après régression statistique en utilisant l'algorithme minimize de la bibliothèque scipy.optimize et la méthode "BFGS", nous obtenons les coefficients 4.633 et 4.337e-02 respectivement pour le temps de trajet et le coût de transport. Ces résultats sont peu encourageants, car il est absurde d'avoir un coefficient positif pour le temps de trajet. Cela signifie que pour un segment donné, plus le trajet est long pour un mode de transport, plus un individu aura tendance à choisir ce mode. En outre, le coefficient du coût est non seulement positif, ce qui est encore une fois absurde, mais également très faible relativement au premier coefficient. Cela semble indiquer que le coût de trajet n'est pas un indicateur explicatif du choix modal sur notre échantillon.

### 4.4.1 Ajout d'un paramètre confort

A ce stade, nous avons fait l'hypothèse que sur notre zone d'étude, les gens ont un biais favorable pour le choix de la voiture qui ne s'explique pas par le temps de trajet ni par la valeur financière mais par la praticité de la voiture ou son confort. Nous avons donc essayé d'ajouter un troisième coefficient, censé permettre au modèle de tenir compte de ce biais favorable envers la voiture. Nous l'avons fixé à 1 pour tous les trajets en voiture et à -1 pour tous les trajets en train. Avec ce nouveau paramètre, la régression computationnelle réalisée nous donne les coefficients 1.381, -2.659e-02 et 1.125 respectivement pour le temps de trajet, le coût financier et le confort. On voit que le coefficient du confort est bien positif, ce qui semble confirmer que les données reflétent un biais positif pour la voiture, ne s'expliquant pas par les deux autres paramètres. Le coefficient du coût est désormais négatif mais surtout il reste extrêmement faible, semblant indiquer en effet une absence de corrélation entre le coût plus attractif d'un mode de transport et le choix de celui-ci. Enfin, le problème majeur, à savoir le fait que le coefficient du temps de trajet soit positif, n'a pas été résolu. On peut noter cependant que celui-ci est tout de même bien plus faible que précédemment, puisqu'il est passé de 4.6 à 1.4.

### 4.4.2 Prédictions des parts modales

À partir des coefficients, dont les valeurs sont absurdes, nous pouvons calculer pour chaque segment la probabilité de le choisir, en réappliquant la formule de l'utilité logistique. On applique ensuite ces probabilités comme des proportions, pour avoir l'effectif moyen qu'on aurait eu sur un grand nombre de tirages. Avec cette méthode, notre modèle prédit bien les mêmes parts d'usagers du train et de la voiture que ceux de la matrice INSEE, à savoir respectivement 15850 et 1015. Quand on l'applique aux matrices d'effectif et de de paramètres calculés avec le graphe de train réouvert, on obtient une part de 18538 et 1121 pour la base INSEE et de 18509 et 1150, soit une augmentation du trafic de transport en commun de 29 personnes parmi l'ensemble des enquêtés mobpro. Non seulement cette augmentation est tout à fait dérisoire mais en plus, il est difficile de comprendre pourquoi on obtient quand même une augmentation des usagers du train. En effet, les coûts n'ont pas changé entre les deux situations et les temps de trajet ont globalement diminué comme on l'a vu dans la figure 4.4b. Or notre coefficient pour les

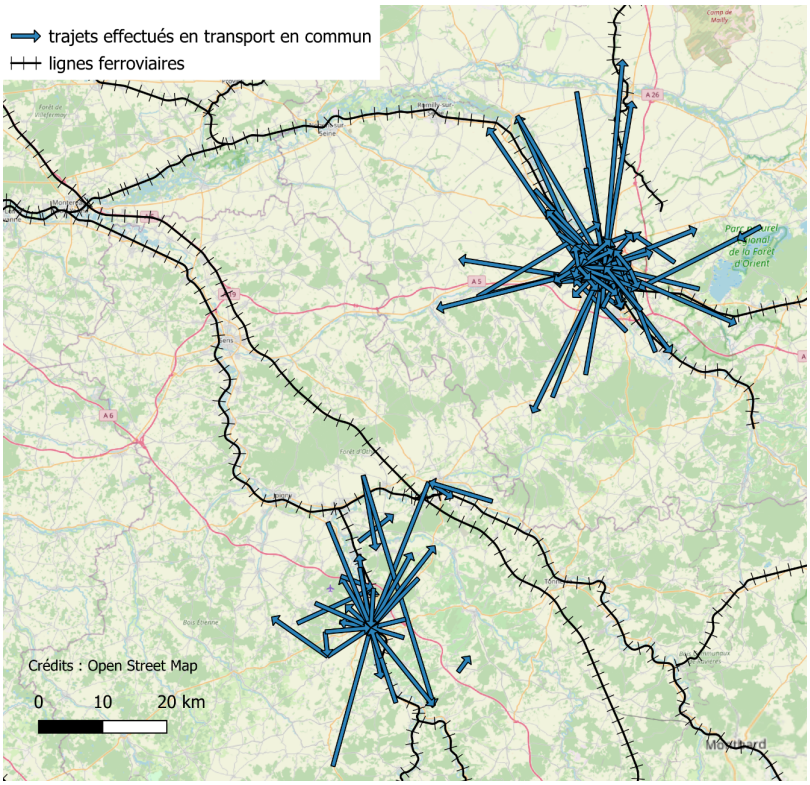



FIGURE 4.6 – Carte des trajets se faisant en train sur notre zone d'étude

temps de trajet est positif, donc cela devrait amener à modéliser une baisse des choix du train.

### 4.4.3 Hypothèses sur l'échec de la méthode et perspectives d'améliorations

L'échec de la modélisation des choix modaux des individus sur notre zone d'étude par la méthode des choix discrets est vraisemblablement dû à une diversité de facteurs.

#### Absence de chiffres spécifiques au train

En premier lieu, nous n'avons pas accès directement à l'effectif de personnes utilisant le train mais uniquement les transports en commun. Or, non seulement il n'est pas évident que les choix de ces deux modes de transport soient modélisables de la même manière mais en plus, nous ne disposons pas des graphes des lignes de bus. Ainsi, les temps de trajet que nous calculons, sur le graphe de train uniquement, sont probablement éloignés des temps de trajet réellement perçus par les usagers, qui eux prennent en compte le temps en bus. On peut en effet voir sur la figure ci-dessous, que certains trajets relativement longs se font sur des axes où il n'y a clairement pas de trajets en train attractifs. C'est le cas d'un certain nombre de trajets qui semblent se faire le long de la N77 et de l'A5, qui n'ont pas d'alternatives en train.

### Faible échantillon de personnes prenant le train sur de longues distances

Notre échantillon de population comprend 23831 personnes prenant soit la voiture soit le train. Parmi ces personnes seulement 1333 personnes prennent le train, soit à peu près 6%, ce qui n'est pas trop faible. Cependant, parmi ces 1333 personnes 645 déclarent un trajet domicile/travail interne à une même commune. Pour ces trajets nous modélisons donc des temps de trajet identiques pour le train et la voiture et il est donc difficile de donner du poids à l'avantage relatif en terme de temps de transport, qui n'apparaît que pour d'assez importantes distances. Une solution pour pallier ce problème serait d'entraîner le modèle sur un cas d'étude avec plus de personnes prenant le train, en particulier sur de longues distances, et appliquer les coefficients trouvés à notre cas d'étude. Une autre solution aurait été de choisir un autre cas d'étude que le nôtre, pour bénéficier d'un cas d'étude où il y aurait à la fois une ligne désaffectée dont la réouverture pourrait être intéressante et d'autres lignes d'assez longue distance déjà bien utilisées. Cependant, ce genre de contraintes nous aurait probablement rapprochés de contextes métropolitains et, partant, de graphes de transport plus compliqués et de situations plus difficiles à modéliser avec des modèles aussi simplificateurs que ceux que nous avons mis en oeuvre.

### Non prise en compte de la congestion

La congestion est un facteur important pour tenter d'expliquer le report modal vers le train. Or, nous n'avons pas pris en compte ce facteur, en particulier pour la N77, concurrente de la ligne dont nous étudions la réouverture et qui est réputée congestionnée.

### Absence de segmentation des ménages selon des caractéristiques socio-économiques et démographiques

Le plus important problème dans notre modélisation est probablement le fait que nous n'avons pas fait de segmentation selon les caractéristiques socio-économiques et démographiques des ménages. Or, sur notre zone d'étude, l'utilisation des transports en commun ou de la voiture est probablement plus un marqueur de classe sociale et de classe d'âge qu'une combinaison linéaire du temps de trajet et du coût financier.

# Conclusion

Pour ce sujet, nous devions d'abord déterminer une zone d'étude. Pour cela, nous nous sommes basées sur le rapport de la FNAUT (Broucaret et al., 2025) qui recense des lignes prioritaires, selon eux, à la réouverture. Après analyse de ces cas, nous avons décidé de nous concentrer sur la ligne qui va de Troyes à Saint-Florentin-Vergigny. Cette ligne remplissait nos critères notamment celui de ne pas être dans une grande métropole. Une fois la zone d'étude décidée, il fallait récupérer les données nécessaires à l'analyse. Nous avons utilisé différentes sources en particulier l'INSEE, SNCF Open Data et OpenStreetMap. Avec ces données, nous pouvons construire les graphes et les matrices requis pour le projet pour chaque moyen de transport.
L'étape d'après est d'ajouter la fréquentation sur chaque arête des graphes. Pour cela, nous approximons le nombre de personnes par trajet et connectons chaque commune au graphe via un noeud très connecté du graphe. Puis nous recherchons le plus court chemin pour chaque paire origine/destination.
Le report modal est calculé selon deux méthodes. Tout d'abord, nous émettons des hypothèses. À partir des chiffres obtenus des lignes rouvertes dans le passé, on voit très clairement les impacts de la réouverture d'une ligne ferroviaire. Les avantages économiques et écologiques sont multiples, et le coût d'une réouverture pour la SNCF, d'après le rapport de la FNAUT (Broucaret et al., 2025), semble minime comparé aux potentielles retombées. Néanmoins, un minimum d'utilisateurs de la ligne est requis pour pouvoir imaginer une réouverture, car si ce taux est trop bas, il n'y aura aucun intérêt à rouvrir la ligne. L'autre méthode est celle du Modèle de Choix Discret. Plutôt que de choisir nous-même les conditions du report modal, nous calculons une matrice de paramètres qui détermine les coefficients de préférence. Avec ces coefficients, nous estimons la probabilité d'être choisi pour chaque tronçon.

# Bibliographie


Beaughon, Antoine et al. (Juin 2025). "Premiers chiffres 2024". In.

Broucaret, Christian et al. (2025). "Plan National de Réouvertures de Lignes ferroviaires". In.

d'Harcourt, Cyprien et al. (Juillet 2023). *Scénarios de long terme pour le réseau ferroviaire français (2022-2042)*. Rapp. tech. Autorité de Régulation des Transports.

Lagourgue, Eléonore, Quentin Rameau-Quinchon et Niels Saura (2025). "Repository github". In : URL : https://github.com/niels31/projet_as.git.

McNally, MG (s. d.). *The four step model. Handbook of transport modelling. 2007 ; 1 : 35–41*.

Wang, Shenhao et al. (2024). "Comparing hundreds of machine learning and discrete choice models for travel demand modeling : An empirical benchmark". In : *Transportation Research Part B : Methodological* 190. ISSN : 0191-2615. DOI : https://doi.org/10.1016/j.trb.2024.103061. URL : https://www.sciencedirect.com/science/article/pii/S0191261524001851.

Yoo, Sunbin et al. (2025). *Railway Expansion Reduces Carbon Emissions by Shifting Road Traffic to Railways*. Rapp. tech. Research Institute of Economy, Trade et Industry (RIETI). URL : https://EconPapers.repec.org/RePEc:eti:dpaper:25006.

# Table des figures

2.1 Ligne de la potentielle réouverture retenue . . . . . 11
2.3 Evolution du pourcentage de trajets internes en fonction de l'augmentation de la population du ROI . . . . . 15

3.1 La couche statut en rouge et la couche vitesse en vert pour la ligne 431000 tronçon 1 . . . . . 17

4.1 Le graphe routier en fonction du passage sur chaque arc . . . . . 22
4.2 Le graphe ferroviaire en fonction du passage sur chaque arc avec ici seulement les lignes encore en activité . . . . . 23
4.3 Graphique représentant la population susceptible de prendre le train en fonction de l'aire d'influence de la gare . . . . . 25
4.5 Tableau comparatif des coûts des voitures les plus en circulation en France en 2022 . . . . . 30
4.6 Carte des trajets se faisant en train sur notre zone d'étude . . . . . 32

# Liste des tableaux